

Спектральные характеристики параметров автокодировщика как векторное представление данных

Мария Александровна Никитина

Московский физико-технический институт

Кафедра: Интеллектуальный анализ данных

Консультант: аспирант А. Ю. Бишук

Научный руководитель: кандидат ф.-м. наук О. Ю. Бахтеев

2025

Постановка задачи

Исследуется взаимосвязь между параметрами моделей автокодировщиков и статистическими свойствами данных, на которых они обучались.

Проблема

Для порождающих моделей исследование связи между параметрами обученной нейронной сети и статистическими свойствами данных имеет ключевое значение. Порождающие модели не просто извлекают закономерности, но и формируют внутренние представления, отражающие структуру распределения данных.

Требуется

Построить векторное представление параметров порождающей модели, сохраняющее статистические свойства исходных данных и их комбинаций. В построенном представлении обеспечить возможность линейного разделения векторов моделей, обученных на выборках, порождённых из разных распределений.

Решение

Проверяется гипотеза о том, что спектральные характеристики параметров обученной нейронной сети образуют плотное векторное представление исходного набора данных.

Обозначения

Пусть p_c — распределение данных класса $c \in \{1, 2, \dots\}$ на $\mathbb{R}^d$.
 $\mathbf{X}_c = \{\mathbf{x}_i : \mathbf{x}_i \sim p_c\}_{i=1}^n$ — выборка, порождённая распределением.


$\mathbf{f}_\psi : \mathbb{R}^d \rightarrow \mathbb{R}^d$ — модель автокодировщика.

$\sigma^{\text{model}} = \sigma_1^{\text{model}}, \dots, \sigma_m^{\text{model}}$ — сингулярные числа матриц параметров модели.

$\sigma^{\text{data}} = \sigma_1^{\text{data}}, \dots, \sigma_m^{\text{data}}$ — сингулярные числа матриц данных.

Подмешивание $\tilde{\mathbf{X}}_{a|b} \in \mathbb{R}^{(n+n) \times d}$ — конкатенация векторов из $\mathbf{X}_a$ и $\mathbf{X}_b$.

Требования к представлению



1. Сохранение возможности разделения моделей, обученных на выборках, порождённых разными распределениями;
2. Устойчивость к вариациям внутри одного распределения;
3. Чувствительность к значимым статистическим различиям.

Предложенный метод

Основная идея

Использование сингулярных чисел матриц параметров как векторного представления модели:

$$\sigma^{\text{model}}(\psi) = \text{CONCAT}(\sigma_1^{\text{model}}(\mathbf{W}_1), \dots, \sigma_s^{\text{model}}(\mathbf{W}_s))$$

Алгоритм

1. Обучение автокодировщика (AE/VAE) на выборке;
2. Извлечение матриц весов из всех слоёв модели;
3. Вычисление сингулярных чисел для каждой матрицы весов;
4. Конкатенация сингулярных чисел в единый вектор;
5. Отбор первых r сингулярных чисел.

Сингулярные числа выборок

Гипотеза

Чем ближе векторы сингулярных чисел исходных выборок, тем хуже линейная разделимость векторов сингулярных чисел соответствующих им моделей.

Лемма (Никитина, 2025)

Пусть заданы матрицы данных $\mathbf{X}_1 \in \mathbb{R}^{n_1 \times d}$, $\mathbf{X}_2 \in \mathbb{R}^{n_2 \times d}$, $\mathbf{X}_3 \in \mathbb{R}^{m \times d}$. Тогда сингулярные числа матриц $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$, образованных подмешиванием векторов $\mathbf{X}_3$ к $\mathbf{X}_1$ и $\mathbf{X}_2$ соответственно, сближаются. То есть:

$$|\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_1) - \sigma_i^{\text{data}}(\tilde{\mathbf{X}}_2)| \longrightarrow 0 \quad \text{при } m \rightarrow \infty$$

где $\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_c)$ — i -ое сингулярное число выборки $\tilde{\mathbf{X}}_c$, образованной подмешиванием векторов $\mathbf{X}_3$ к $\mathbf{X}_c$.

Связь сингулярных чисел параметров модели с данными

Теорема (Никитина, 2025)

$\tilde{\mathbf{X}}_c = [\mathbf{X}_c, \mathbf{X}_3] \in \mathbb{R}^{(n+m) \times d}$, $c \in \{1, 2\}$ — новые выборки, сформированные подмешиванием.

На каждой выборке обучена модель линейного автокодировщика, минимизирующая функцию ошибки:

$$\min_{\psi_c} (\mathcal{L}(\psi_c)) = \min_{\psi_c} \|\tilde{\mathbf{X}}_c - \tilde{\mathbf{X}}_c \mathbf{W}_c^{enc} \mathbf{W}_c^{decT}\|_F^2$$

с регуляризацией вида $\|\text{cov}(\mathbf{h}) - \mathbf{I}\|^2$, декоррелирующей векторы $\mathbf{h}$ из скрытого пространства, то есть $\text{cov}(\mathbf{h}) \sim \mathbf{I}$.

Тогда средний квадрат разности между сингулярными числами параметров автокодировщиков:

$$\|\sigma_i^{\text{model}}(\mathbf{W}_1^{enc}) - \sigma_i^{\text{model}}(\mathbf{W}_2^{enc})\|_2 \xrightarrow{m \rightarrow \infty} 0$$

Настройки вычислительного эксперимента

Данные

1. CIFAR-10: 3 наиболее отличающихся класса;
2. FashionMNIST: все 10 классов.

Модели

1. Автокодировщик и вариационный автокодировщик;
2. Архитектура: 1-2 линейных слоя, скрытое пространство размерности 256.


Метрики

1. Accuracy, ROC AUC, Average Precision;
2. Классификация: логистическая регрессия с L_2 -регуляризацией;
3. Статистика: среднее по 5 запускам с различными подвыборками.

Базовый эксперимент

Разделение двух классов

1. Для линейных AE: Accuracy = $0.98(\pm 0.02)$;
2. Для VAE: Accuracy = $0.97(\pm 0.03)$;




Векторы сингулярных чисел позволяют почти идеально разделять модели, обученные на разных классах.

Подмешивание третьего класса

Зависимость качества от доли третьего класса


1. Эксперимент для 3 различных вариантов семплирования третьего класса;
2. Качество существенно зависит от α — доли третьего класса в выборке.



Корреляция с сингулярными числами данных

Подтверждение Теоремы

Расстояние между векторами сингулярных чисел матриц параметров моделей линейно зависит от расстояния между сингулярными числами выборок.



Попарные сравнения классов

Матрица разделимости для FashionMNIST

Качество разделения векторов моделей с помощью логистической регрессии коррелирует с визуальным и статистическим различием классов.

	T-shirt/Top	Trouser	Pullover	Dress	Coat	Sandals	Shirt	Sneaker	Bag	Ankle Boots
T-shirt/Top	1.00	0.00	0.02	0.02	0.00	0.00	0.05	0.00	0.00	0.00
Trouser	1.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Pullover	0.95	1.00	1.00	0.02	0.01	0.00	0.01	0.00	0.00	0.00
Dress	0.93	1.00	0.94	1.00	0.02	0.00	0.02	0.01	0.00	0.02
Coat	1.00	1.00	0.97	0.93	1.00	0.00	0.02	0.00	0.00	0.00
Sandals	1.00	1.00	1.00	1.00	1.00	1.00	0.03	0.00	0.00	0.00
Shirt	0.85	1.00	0.97	0.94	0.93	0.93	1.00	0.00	0.00	0.00
Sneaker	1.00	1.00	1.00	0.97	1.00	1.00	1.00	1.00	0.00	0.00
Bag	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	0.00
Ankle Boots	1.00	1.00	1.00	0.95	1.00	1.00	1.00	1.00	1.00	1.00

Нижняя треугольная матрица — среднее качество логистической регрессии при разделении векторов моделей, верхняя треугольная матрица — std качества логистической регрессии, диагональ — среднее качество логистической регрессии в эксперименте one-vs-rest.

1. Разработан метод векторизации моделей на основе сингулярных чисел параметров;
2. Доказана теоретическая связь спектра параметров и данных для моделей автокодировщиков. Векторы сингулярных чисел параметров моделей ближе при схожих распределениях, порождающих обучающие данные.
3. С помощью нескольких серий экспериментов проанализировано поведение сингулярных чисел моделей в зависимости от обучающей выборки. Экспериментально подтверждено утверждение теоремы.

1. Статья подана на публикацию на русском языке и находится на рецензировании в журнал Управление большими системами.