
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа Прикладной Математики и Информатики
Кафедра интеллектуальных систем

Направление подготовки / специальность: 09.04.01 Информатика и вычислительная техника

Направленность (профиль) подготовки: Прикладная математика и информатика

СПЕКТРАЛЬНЫЕ ХАРАКТЕРИСТИКИ ПАРАМЕТРОВ АВТОКОДИРОВЩИКА КАК ВЕКТОРНОЕ ПРЕДСТАВЛЕНИЕ ДАННЫХ

(магистерская диссертация)

Студент:

Никитина Мария Александровна

(подпись студента)

Научный руководитель:

Бахтеев Олег Юрьевич,
канд. физ.-мат. наук

(подпись научного руководителя)

Консультант (при наличии):

(подпись консультанта)

Москва 2026

АННОТАЦИЯ

В работе исследуется взаимосвязь между параметрами моделей автокодировщиков и статистическими свойствами данных, на которых они обучались. Под автокодировщиками понимаются модели с архитектурой кодировщик - декодировщик, обучаемые восстанавливать входные данные через сжатое латентное представление. Вводится предположение, что спектральные характеристики параметров модели могут рассматриваться как плотное векторное представление соответствующей выборки. Для проверки этой гипотезы проводится теоретическое и экспериментальное исследование, в котором формируется векторное представление на основе спектральных характеристик матриц параметров автокодировщика. Теоретический анализ показывает, что сингулярные числа матриц параметров моделей связаны с собственными значениями ковариационной матрицы обучающих данных, что обеспечивает передачу информации между пространством данных и пространством параметров. Экспериментальные результаты на наборах CIFAR-10 и FashionMNIST подтверждают, что полученные векторные представления позволяют с высокой точностью различать модели, обученные на различных подмножествах данных, без привлечения сложных алгоритмов формирования векторов и использования исходных выборок. Эти результаты свидетельствуют о том, что спектральные характеристики параметров обученных автокодировщиков могут рассматриваться как представления выборок.

Ключевые слова: машинное обучение, нейронные сети, векторное представление, автокодировщик, спектральные характеристики, порождающие модели

Содержание

1 Введение	4
2 Постановка задачи	6
3 Предложенный метод	10
4 Вычислительный эксперимент	25
4.1 Методика и настройки	25
4.2 Базовый эксперимент (два класса)	26
4.3 Эксперимент с подмешиванием третьего класса	27
4.4 Эксперимент с добавлением случайных объектов	30
4.5 Корреляция с сингулярными числами выборки	31
4.6 Попарные сравнения (каждый класс против каждого)	32
4.7 Вывод из экспериментов	33
5 Заключение	34

1 Введение

Методы машинного обучения, основанные на искусственных нейронных сетях, прочно утвердились в качестве важного инструментария, находящего применение в различных областях современного анализа данных [1, 2]. Связь между структурой обученных нейронных сетей и статистическими свойствами данных, на которых они обучались, является одной из фундаментальных проблем современного машинного обучения [24]. Понимание того, каким образом распределение обучающих данных отражается в параметрах модели, имеет ключевое значение для таких направлений, как интерпретация нейронных сетей, анализ свойств данных, выбор архитектуры и построение мета-представлений моделей [3, 4, 8, 20, 26]. Кроме того, это делает данную проблему особенно актуальной для порождающих моделей, поскольку они не просто извлекают закономерности, но и формируют внутренние представления, отражающие структуру распределения данных [23, 30]. Данная работа фокусируется на автокодировщиках — нейронных сетях, основанных на архитектуре кодировщик-декодировщик. Хотя их классическая архитектура формально не является порождающей, регуляризованные версии приближаются или даже представляют собой полноценные порождающие модели [6, 17, 21]. Таким образом, анализ структуры параметров автокодировщика естественным образом связан с более широким классом порождающих моделей, и результаты данной работы потенциально могут быть обобщены на этот класс.

Существует широкий спектр исследований, направленных на построение векторных представлений моделей. Классические подходы используют кодирование архитектурных параметров [9, 11], мета-представления, полученные через отдельные модели [10, 25], или представления, формируемые на основе результатов работы модели на тестовых данных [16]. В недавних работах было предложено рассматривать модель как точку в непрерывном пространстве, что позволяет проводить поиск, интерполяцию и анализ моделей [7, 15]. Однако большинство таких методов либо требует прямого

доступа к исходным данным, либо основывается на сложных процедурных эвристиках, объединяющих результаты промежуточных вычислений, архитектурные признаки или метайнформацию.

В настоящей работе рассматривается другой подход. Исследуется, насколько параметры обученной модели могут служить репрезентативным описанием данных, на которых происходило обучение. Проверяется гипотеза о том, что спектральные характеристики параметров обученной нейронной сети образуют плотное векторное представление исходного набора данных. Таким образом, обученная модель выступает в роли эмбединга выборки, а её параметры выполняют роль носителя статистических характеристик распределения данных [19, 22].

Для демонстрации подхода предлагается метод векторизации модели, основанный на анализе сингулярных чисел матриц параметров модели. Показано, что метод позволяет решать задачу разделения моделей, обученных на разных данных, с высокой точностью. Этот результат указывает на наличие глубокой связи между спектральными свойствами параметров и статистикой обучающих выборок. В отличие от подходов, основанных на внешних признаках или аппроксимациях распределения данных, в предложенном подходе рассматривается исключительно пространство параметров модели без доступа к исходным данным и дополнительного обучения вспомогательных сетей.

В теоретической части работы приводится обоснование взаимосвязи между сингулярными числами параметров модели и спектром ковариационной матрицы данных. Показано, что в случае автокодировщиков с полносвязными слоями сингулярные числа обученных весов модели несут информацию о распределении обучающих выборок. Кроме того, доказано, что при наличии различий между исходными данными получившиеся представления также различаются.

Экспериментальная часть направлена на проверку гипотезы о том, что даже при использовании неглубоких архитектур семейства автокодировщиков (АЕ) и вариационных автокодировщиков (VAE), а также необучаемых методов векторизации, основанных исключительно на параметрах модели, можно с высокой точностью различать модели, обученные на разных подмножествах данных. Эксперименты на наборах CIFAR-10 [18] и FashionMNIST [29] подтверждают, что классификация таких моделей по векторному представлению достигает высоких значений метрик классификации — Accuracy, ROC AUC и Average Precision. Более того, постепенное добавление новых классов или шумовых примесей в обучающую выборку предсказуемым образом отражается на векторных представлениях, что свидетельствует о корректной геометрии пространства моделей.

Полученные результаты позволяют рассматривать параметры нейронных сетей как метод описания данных. В этом смысле обученные модели становятся не только инструментом для генерации или аппроксимации данных, но и естественным эмбедингом для анализа структуры и взаимосвязей между выборками.

2 Постановка задачи

Пусть p_c — распределение данных класса $c \in \{1, 2, \dots\}$ на $\mathbb{R}^d$ — пространстве векторов размерности d . Пусть задана выборка $\mathbf{X}_c = \{\mathbf{x}_i : \mathbf{x}_i \sim p_c\}_{i=1}^n$. Выборки могут состоять из нескольких классов, каждому из которых будет соответствовать свое распределение p_c . В классической постановке задачи без учителя $c \equiv 1$ и $p_c \equiv p_1 \equiv p$, а $\mathbf{X}_c \equiv \mathbf{X}_1 \equiv \mathbf{X}$.

Рассматривается семейство моделей автокодировщиков. Модель задаётся как параметризованная функция $\mathbf{f}_\psi : \mathbb{R}^d \rightarrow \mathbb{R}^d$, представляющая собой композицию кодировщика и декодировщика, $\mathbf{f}_\psi = D_\varphi \circ E_\theta$. Параметры модели $\psi = (\theta, \varphi) \in \Psi$, где $E_\theta : \mathbb{R}^d \rightarrow \mathbb{R}^z$ — кодировщик с параметрами θ , а $D_\varphi : \mathbb{R}^z \rightarrow \mathbb{R}^d$ — декодировщик с параметрами φ . Здесь z — раз-

мер скрытого пространства. Обучение осуществляется путём минимизации функции

$$\mathcal{L}(\psi; p_c) := -\mathbb{E}_{\mathbf{x} \sim p_c} [l_\psi(\mathbf{x})],$$

где максимизируемый функционал $l_\psi(\mathbf{x})$ принимает вид:

$$l_\psi(\mathbf{x}) = \begin{cases} -\ell(\mathbf{x}, \mathbf{f}_\psi(\mathbf{x})), & \text{для АЕ,} \\ \mathbb{E}_{\mathbf{h} \sim q_\theta(\mathbf{h}|\mathbf{x})} [-\ell(\mathbf{x}, D_\varphi(\mathbf{h}))] & \text{для VAE,} \\ -\text{KL}(q_\theta(\mathbf{h} | \mathbf{x}) \parallel p(\mathbf{h})), & \end{cases}$$

где $\ell : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ – функция потерь реконструкции (например, средне-квадратичная ошибка или кросс-энтропия), оценивающая различия между входным вектором $\mathbf{x}$ и его реконструкцией, $\text{KL}(\cdot \parallel \cdot)$ обозначает дивергенцию Кульбака–Лейблера – меру различия между двумя вероятностными распределениями, $q_\theta(\mathbf{h} | \mathbf{x})$ – аппроксимирующее (вариационное) распределение в скрытом пространстве, параметризуемое кодировщиком, а $p(\mathbf{h})$ – априорное распределение в скрытом пространстве (стандартное – многомерное нормальное $\mathcal{N}(\mathbf{0}, \mathbf{I})$).

Для обычного автокодировщика (АЕ) функционал сводится к минимизации ошибки реконструкции. Для вариационного автокодировщика (VAE) функционал состоит из двух слагаемых: средней ошибки реконструкции (ожидание берется по скрытой переменной $\mathbf{h}$) и регуляризующего члена KL, который отвечает за сближение распределения кодировщика $q_\theta(\mathbf{h} | \mathbf{x})$ к заданному априорному распределению $p(\mathbf{h})$.

Пусть имеется множество порождающих моделей, каждая из которых обучена на собственном наборе данных, описывающем определённую генеральную совокупность. Требуется построить пространство представлений, в котором каждая модель отображается в плотный вектор, сохраняющий статистические свойства исходных данных. Такое пространство должно позволять проводить анализ свойств как самих выборок, так и обученных на

них моделей без необходимости повторного обучения или прямого доступа к исходным данным. При этом вектор не обязан однозначно восстанавливать исходную модель, а лишь должен описывать ряд заранее заданных свойств.

Ключевым свойством искомого представления является сохранение возможности разделять модели, обученные на выборках, порождённых различными распределениями p . Пусть существует некоторое пространство, в котором наборы данных $\mathbf{X}_a \in \mathbb{R}^{n_a \times d}$, $\mathbf{X}_b \in \mathbb{R}^{n_b \times d}$, $\mathbf{X}_c \in \mathbb{R}^{n_c \times d}$ линейно разделимы. Такое же требование предъявляется к векторам порождающих моделей, обученных на подмножествах объектов из этих наборов.

Вводится векторное представление моделей и данных на основе сингулярных чисел. Пусть параметры модели ψ представлены в виде набора матриц весов $\{\mathbf{W}_l\}_{l=1}^L$ по её слоям.

Сингулярные числа модели $\sigma^{\text{model}}(\psi)$ определяются алгоритмически (Алгоритм 1): для каждой матрицы $\mathbf{W}_l$ вычисляется r наибольших сингулярных чисел; полученные векторы конкатенируются по порядку слоёв и нормируются. Вектор $\sigma^{\text{model}}(\psi)$ однозначно задаётся параметрами и архитектурой модели. Сингулярные числа данных $\sigma^{\text{data}}(\mathbf{X}_c)$ для выборки $\mathbf{X}_c$ — это вектор её t наибольших сингулярных чисел, упорядоченных по убыванию.

Определение 1. Пусть заданы наборы векторов $\mathbf{X}_a \in \mathbb{R}^{n \times d}$ и $\mathbf{X}_b \in \mathbb{R}^{m \times d}$. Вводится понятие подмешивания — конкатенации векторов из $\mathbf{X}_a$ и $\mathbf{X}_b$ для получения $\tilde{\mathbf{X}}_{a|b} \in \mathbb{R}^{(n+m) \times d}$.

α -подмешивание — конкатенация $\mathbf{X}_a$ и $\lfloor \alpha t \rfloor$, $\alpha \in [0; 1]$ векторов из $\mathbf{X}_b$ для получения $\tilde{\mathbf{X}}_{a|b} \in \mathbb{R}^{(n+\lfloor \alpha t \rfloor) \times d}$.

Тогда подмешивание объектов из $\mathbf{X}_c$ к $\mathbf{X}_a$ и $\mathbf{X}_b$ должно сближать новые наборы данных $\mathbf{X}_{a+c}$, $\mathbf{X}_{b+c}$, что изображено на Рис. 1 (а), то есть ухудшать их линейную разделимость, как показано на Рис. 1 (б). Векторное представление порождающих моделей, обученных на объектах из выбранных наборов данных, должно удовлетворять тем же свойствам.




Рис. 1: Схематичное отображение отношений между наборами данных в пространстве векторных представлений: **а)** При подмешивании к выборке **a** и **b** векторов третьей выборки **c** векторы результирующих выборок **a + c** и **b + c** сближаются; **б)** При достаточном сближении вектора результирующих выборок перестают быть линейно разделимы.

Кроме того, представление должно быть устойчивым к вариациям внутри одного и того же распределения данных и при этом чувствительным к значимым статистическим различиям между выборками. Важной задачей является оценка того, насколько вектор модели сохраняет информацию об исходной выборке. Для этого необходимо рассматривать не только точность восстановления исходных данных, но и способность представления отражать структуру и взаимосвязи между выборками.

Таким образом, задача сводится к построению отображения из параметров порождающей модели в плотное векторное пространство с сохранением статистических свойств исходных данных и их комбинаций. Для её решения в данной работе используется метод, основанный на спектральных характеристиках матриц параметров модели, который позволяет формировать интерпретируемые и информативные векторные представления.

3 Предложенный метод

В основе предлагаемого подхода лежит идея представления модели f в виде плотного вектора, содержащего информацию о статистических свойствах данных X_c , на которых она была обучена. Для этого используются $\sigma^{\text{model}}(\psi)$ — сингулярные числа матриц параметров ψ , извлекаемые из обученной модели. Такой выбор обусловлен тем, что спектральная структура параметров нейронной сети отражает ключевые особенности распределения входных данных, а σ^{model} оказываются чувствительными к статистическим различиям между выборками, что будет теоретически обосновано далее.

Формализованная схема алгоритма 1 иллюстрирует ключевые шаги предложенного подхода.

Algorithm 1 Построение векторного представления порождающей модели

Require: Обученная модель с числом слоёв L , набор матриц параметров $\{\mathbf{W}_l\}_{l=1}^L$. r — число сингулярных чисел, отбираемых для построения вектора модели.

Ensure: Векторное представление модели $\mathbf{v}$

- 1: Инициализировать пустой вектор признаков $\mathbf{v} \leftarrow []$;
 - 2: **for** каждый слой $\mathbf{W}_l$ в модели **do**
 - 3: Выполнить сингулярное разложение $\mathbf{W}_l = \mathbf{U}_l \mathbf{S}_l \mathbf{V}_l^T$;
 - 4: Извлечь сингулярные числа $\sigma_{l,1}^{\text{model}}, \dots, \sigma_{l,k_l}^{\text{model}}$ из $\mathbf{S}_l$;
 - 5: Отсортировать сингулярные числа по убыванию;
 - 6: Оставить r наибольших сингулярных чисел;
 - 7: Добавить полученные значения в $\mathbf{v}$.
 - 8: **end for**
 - 9: Нормализовать $\mathbf{v}$ (например, до единичной нормы);
 - 10: **return** $\mathbf{v}$
-

Замечание. Число r из алгоритма может быть взято как минимальное число сингулярных чисел первого слоя, которые составляют заранее заданную долю от суммы всех сингулярных чисел этого слоя.

Для теоретического обоснования предложенного метода необходимо оценить взаимосвязь σ^{model} и σ^{data} . Пусть существует некоторое векторное пространство, в котором векторы сингулярных чисел различных выборок линейно разделимы. Требуется доказать, что вектора сингулярных чисел параметров порождающих моделей, обученных на подмножествах из данных выборок, также можно линейно разделить.

Гипотеза. *Чем ближе векторы сингулярных чисел исходных выборок, тем хуже линейная разделимость векторов сингулярных чисел соответствующих им моделей.*

Пусть существует $V_\sigma \subset \mathbb{R}^d$ — пространство векторов сингулярных чисел выборок. Для доказательства гипотезы 3, сближение $\sigma^{\text{data}}(\mathbf{X}_1) \in V_\sigma$ и $\sigma^{\text{data}}(\mathbf{X}_2) \in V_\sigma$ для матриц данных $\mathbf{X}_1$ и $\mathbf{X}_2$ соответственно предлагается осуществлять посредством подмешивания объектов третьей выборки $\mathbf{X}_3$. Для демонстрации того, что сингулярные числа $\tilde{\mathbf{X}}_{c|3}$, полученные конкатенацией $\mathbf{X}_c$ и $\mathbf{X}_3$ для $c \in \{1, 2\}$, сближаются при увеличении доли объектов из $\mathbf{X}_3$, была доказана лемма 1. Далее, для упрощения записи, в утверждениях $\tilde{\mathbf{X}}_c \equiv \tilde{\mathbf{X}}_{c|3}$ для $c \in \{1, 2\}$.

Лемма 1. *Пусть заданы $\mathbf{X}_1 \in \mathbb{R}^{n_1 \times d}$ — матрица данных первой выборки (n_1 объектов, d признаков), $\mathbf{X}_2 \in \mathbb{R}^{n_2 \times d}$ — матрица данных второй выборки, $\mathbf{X}_3 \in \mathbb{R}^{m \times d}$ — матрица данных третьей выборки.*

Тогда $\sigma^{\text{data}}(\tilde{\mathbf{X}}_1)$, $\sigma^{\text{data}}(\tilde{\mathbf{X}}_2)$ — сингулярные числа матриц $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$ сближаются: $|\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_1) - \sigma_i^{\text{data}}(\tilde{\mathbf{X}}_2)| \rightarrow 0$ при $m \rightarrow \infty$, где $\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_c)$ — i -ое сингулярное число выборки $\tilde{\mathbf{X}}_c$, образованной подмешиванием векторов $\mathbf{X}_3$ к $\mathbf{X}_c$.

Доказательство. Матрицы ковариаций исходных выборок можно представить в развернутом виде как $\Sigma_c = \frac{1}{n_c} \mathbf{X}_c^\top \mathbf{X}_c - \boldsymbol{\mu}_c \boldsymbol{\mu}_c^\top$, где $\boldsymbol{\mu}_c$ — векторы средних значений.

Для $\tilde{\mathbf{X}}_1 = [\mathbf{X}_1; \mathbf{X}_3]$ новый вектор средних значений является взвешенным средним составляющих векторов: $\tilde{\boldsymbol{\mu}}_1 = \frac{n_1\boldsymbol{\mu}_1 + m\boldsymbol{\mu}_3}{n_1 + m}$. После центрирования данных:

$$\tilde{\mathbf{X}}_1^{centered} = \tilde{\mathbf{X}}_1 - \mathbf{1}_{n_1+m}\tilde{\boldsymbol{\mu}}_1^\top = \begin{bmatrix} \mathbf{X}_1 - \mathbf{1}_{n_1}\tilde{\boldsymbol{\mu}}_1^\top \\ \mathbf{X}_3 - \mathbf{1}_m\tilde{\boldsymbol{\mu}}_1^\top \end{bmatrix},$$

где $\mathbf{1}_k$ — единичный вектор длины k .

Выражение для ковариационной матрицы для $\tilde{\mathbf{X}}_1$:

$$\begin{aligned} \tilde{\Sigma}_1 &= \frac{1}{n_1 + m} \left(\tilde{\mathbf{X}}_1^{centered} \right)^\top \tilde{\mathbf{X}}_1^{centered} \\ &= \frac{1}{n_1 + m} \left((\mathbf{X}_1 - \mathbf{1}_{n_1}\tilde{\boldsymbol{\mu}}_1^\top)^\top (\mathbf{X}_1 - \mathbf{1}_{n_1}\tilde{\boldsymbol{\mu}}_1^\top) \right. \\ &\quad \left. + (\mathbf{X}_3 - \mathbf{1}_m\tilde{\boldsymbol{\mu}}_1^\top)^\top (\mathbf{X}_3 - \mathbf{1}_m\tilde{\boldsymbol{\mu}}_1^\top) \right). \end{aligned}$$

Слагаемые можно выразить следующим образом:

$$\begin{aligned} &(\mathbf{X}_1 - \mathbf{1}_{n_1}\tilde{\boldsymbol{\mu}}_1^\top)^\top (\mathbf{X}_1 - \mathbf{1}_{n_1}\tilde{\boldsymbol{\mu}}_1^\top) \\ &= \mathbf{X}_1^\top \mathbf{X}_1 - n_1\boldsymbol{\mu}_1\tilde{\boldsymbol{\mu}}_1^\top - n_1\tilde{\boldsymbol{\mu}}_1\boldsymbol{\mu}_1^\top + n_1\tilde{\boldsymbol{\mu}}_1\tilde{\boldsymbol{\mu}}_1^\top; \end{aligned} \quad (1)$$

$$\begin{aligned} &(\mathbf{X}_3 - \mathbf{1}_m\tilde{\boldsymbol{\mu}}_1^\top)^\top (\mathbf{X}_3 - \mathbf{1}_m\tilde{\boldsymbol{\mu}}_1^\top) \\ &= \mathbf{X}_3^\top \mathbf{X}_3 - m\boldsymbol{\mu}_3\tilde{\boldsymbol{\mu}}_1^\top - m\tilde{\boldsymbol{\mu}}_1\boldsymbol{\mu}_3^\top + m\tilde{\boldsymbol{\mu}}_1\tilde{\boldsymbol{\mu}}_1^\top. \end{aligned} \quad (2)$$

Так как выражение для вектора средних значений новой матрицы можно переписать в виде:

$$\tilde{\boldsymbol{\mu}}_1 = \frac{n_1\boldsymbol{\mu}_1 + m\boldsymbol{\mu}_3}{n_1 + m} \Rightarrow n_1\boldsymbol{\mu}_1 + m\boldsymbol{\mu}_3 = (n_1 + m)\tilde{\boldsymbol{\mu}}_1,$$

то слагаемое из суммы правых частей выражений 1 и 2:

$$n_1\boldsymbol{\mu}_1\tilde{\boldsymbol{\mu}}_1^\top + m\boldsymbol{\mu}_3\tilde{\boldsymbol{\mu}}_1^\top = (n_1 + m)\tilde{\boldsymbol{\mu}}_1\tilde{\boldsymbol{\mu}}_1^\top = n_1\tilde{\boldsymbol{\mu}}_1\boldsymbol{\mu}_1^\top + m\tilde{\boldsymbol{\mu}}_1\boldsymbol{\mu}_3^\top.$$

Следовательно, матрица ковариации новой выборки:

$$\tilde{\Sigma}_1 = \frac{1}{n_1 + m} (\mathbf{X}_1^\top \mathbf{X}_1 + \mathbf{X}_3^\top \mathbf{X}_3) - \tilde{\boldsymbol{\mu}}_1 \tilde{\boldsymbol{\mu}}_1^\top.$$

Аналогично можно записать и для $\tilde{\mathbf{X}}_2$:

$$\tilde{\Sigma}_2 = \frac{1}{n_2 + m} (\mathbf{X}_2^\top \mathbf{X}_2 + \mathbf{X}_3^\top \mathbf{X}_3) - \tilde{\boldsymbol{\mu}}_2 \tilde{\boldsymbol{\mu}}_2^\top.$$

Отсюда следует их разность:

$$\begin{aligned} \tilde{\Sigma}_1 - \tilde{\Sigma}_2 &= \frac{\mathbf{X}_1^\top \mathbf{X}_1}{n_1 + m} - \frac{\mathbf{X}_2^\top \mathbf{X}_2}{n_2 + m} + \left(\frac{1}{n_1 + m} - \frac{1}{n_2 + m} \right) \mathbf{X}_3^\top \mathbf{X}_3 \\ &\quad - (\tilde{\boldsymbol{\mu}}_1 \tilde{\boldsymbol{\mu}}_1^\top - \tilde{\boldsymbol{\mu}}_2 \tilde{\boldsymbol{\mu}}_2^\top). \end{aligned}$$

При увеличении m норма первой части разности убывает как $O(\frac{1}{m})$:

$$\left\| \frac{\mathbf{X}_1^\top \mathbf{X}_1}{n_1 + m} - \frac{\mathbf{X}_2^\top \mathbf{X}_2}{n_2 + m} \right\|_2 = O\left(\frac{1}{m}\right) \quad \text{при } m \rightarrow \infty.$$

Норма второй части $\left(\frac{1}{n_1 + m} - \frac{1}{n_2 + m} \right) \mathbf{X}_3^\top \mathbf{X}_3$ оценивается как:

$$\begin{aligned} \frac{n_2 - n_1}{(n_1 + m)(n_2 + m)} \mathbf{X}_3^\top \mathbf{X}_3 &= \frac{m(n_2 - n_1)}{(n_1 + m)(n_2 + m)} (\Sigma_3 + \boldsymbol{\mu}_3 \boldsymbol{\mu}_3^\top) \\ &= O\left(\frac{1}{m}\right). \end{aligned}$$

Для третьей части: $\tilde{\boldsymbol{\mu}}_1 \tilde{\boldsymbol{\mu}}_1^\top - \tilde{\boldsymbol{\mu}}_2 \tilde{\boldsymbol{\mu}}_2^\top = (\tilde{\boldsymbol{\mu}}_1 - \tilde{\boldsymbol{\mu}}_2) \tilde{\boldsymbol{\mu}}_1^\top + \tilde{\boldsymbol{\mu}}_2 (\tilde{\boldsymbol{\mu}}_1 - \tilde{\boldsymbol{\mu}}_2)^\top$. Поскольку $\tilde{\boldsymbol{\mu}}_1$ и $\tilde{\boldsymbol{\mu}}_2$ стремятся к $\boldsymbol{\mu}_3$ (ограничены), а $|\tilde{\boldsymbol{\mu}}_1 - \tilde{\boldsymbol{\mu}}_2| = O(\frac{1}{m})$, то третья часть имеет асимптотику $O(\frac{1}{m})$.

Из теории матричных возмущений (теорема Вейля для сингулярных чисел [28]) следует, что для i -го сингулярного числа выполнено неравенство: $|\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_1) - \sigma_i^{\text{data}}(\tilde{\mathbf{X}}_2)| \leq \|\tilde{\mathbf{X}}_1 - \tilde{\mathbf{X}}_2\|_2$. Таким образом, модуль разности i -ых

сингулярных чисел новых выборок уменьшается как $O\left(\frac{1}{m}\right)$ при $m \rightarrow \infty$:

$$|\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_1) - \sigma_i^{\text{data}}(\tilde{\mathbf{X}}_2)| = O\left(\frac{1}{m}\right).$$

□

Иными словами, сингулярные числа смесей $\tilde{\mathbf{X}}_c$ сближаются при увеличении доли объектов из $\mathbf{X}_3$. Теперь можно перейти к доказательству теоремы 1 о связи между сингулярными числами выборки и весами модели.

Далее формулируется и доказывается теорема для частного случая автокодировщика — автокодировщика с одним полносвязным слоем в кодировщике и декодировщике без нелинейной функции активации. Вводится $\mathbf{W}_c^{\text{enc}}$ — матричное обозначение параметров $\boldsymbol{\theta}_c$ кодировщика модели, $\mathbf{W}_c^{\text{dec}}$ — матричное обозначение параметров $\boldsymbol{\varphi}_c$ декодировщика модели.

Теорема 1. Пусть заданы три выборки: $\mathbf{X}_1 \in \mathbb{R}^{n \times d}$, $\mathbf{X}_2 \in \mathbb{R}^{n \times d}$, $\mathbf{X}_3 \in \mathbb{R}^{m \times d}$; их сингулярные числа больше 0: $\sigma_i^{\text{data}}(\mathbf{X}_c) > 0 \quad \forall i \in \overline{1, d}$.

Пусть получены две новые выборки, сформированные путём подмешивания в выборку векторов из третьего набора данных: $\tilde{\mathbf{X}}_c = [\mathbf{X}_c, \mathbf{X}_3] \in \mathbb{R}^{(n+m) \times d}$, $c \in \{1, 2\}$.

Пусть также на каждой выборке обучена модель автокодировщика с полносвязными слоями без нелинейной функции активации со скрытой размерностью k , минимизирующая функцию ошибки $\min_{\psi_c}(\mathcal{L}(\psi_c)) = \min_{\psi_c} \|\tilde{\mathbf{X}}_c - \tilde{\mathbf{X}}_c \mathbf{W}_c^{\text{enc}} \mathbf{W}_c^{\text{dec} \top}\|_F^2$ с регуляризацией вида $\|\text{cov}(\mathbf{h}) - \mathbf{I}\|^2$, декоррелирующей векторы $\mathbf{h}$ из скрытого пространства, то есть $\text{cov}(\mathbf{h}) \sim I$.

Утверждается, что средний квадрат разности между сингулярными числами параметров автокодировщиков с параметрами $\mathbf{W}_1^{\text{enc}}$, $\mathbf{W}_1^{\text{dec}}$, $\mathbf{W}_2^{\text{enc}}$, $\mathbf{W}_2^{\text{dec}}$ будет уменьшаться при увеличении m :

$$\|\sigma_i^{\text{model}}(\mathbf{W}_1^{\text{enc}}) - \sigma_i^{\text{model}}(\mathbf{W}_2^{\text{enc}})\|_2 \xrightarrow{m \rightarrow \infty} 0,$$

Следовательно, при сближении выборок будут сближаться как их сингулярные числа, так и сингулярные числа параметров автокодировщиков, обученных на этих выборках при стремлении числа строк t к бесконечности.

Доказательство. Задана добавка к функции потерь $\|\text{cov}(\mathbf{h}_c) - \mathbf{I}\|_2^2$. Ковариация векторов скрытого пространства $\mathbf{h}_c = \mathbf{W}_c^{enc} \mathbf{x}_c$, удовлетворяющих данной добавке к функции потерь, может быть представлена следующим образом:

$$\begin{aligned} \text{cov}(\mathbf{h}_c) &= \mathbb{E}[(\mathbf{W}_c^{enc} \mathbf{x}_c - \mathbf{W}_c^{enc} \boldsymbol{\mu}_{\mathbf{x}_c})(\mathbf{W}_c^{enc} \mathbf{x}_c - \mathbf{W}_c^{enc} \boldsymbol{\mu}_{\mathbf{x}_c})^\top] \\ &= \mathbb{E}[\mathbf{W}_c^{enc} (\mathbf{x}_c - \boldsymbol{\mu}_{\mathbf{x}_c})(\mathbf{x}_c - \boldsymbol{\mu}_{\mathbf{x}_c})^\top (\mathbf{W}_c^{enc})^\top] \\ &= \mathbf{W}_c^{enc} \text{cov}(\mathbf{x}_c) (\mathbf{W}_c^{enc})^\top \approx \mathbf{I}. \end{aligned}$$

Так как матрица ковариации $\mathbf{x}_c$ может быть выражена как $\text{cov}(\mathbf{x}_c) = \mathbf{V}_c \boldsymbol{\Lambda}_c \mathbf{V}_c^\top$, где $\boldsymbol{\Lambda}_c = \text{Diag}(\lambda_1^c, \dots, \lambda_d^c)$, $\lambda_i^c > 0$, $\mathbf{V}_c$ — ортонормированная, то матрица ковариации скрытых представлений $\mathbf{h}_c$ выглядит следующим образом:

$$\mathbf{W}_c^{enc} \mathbf{V}_c \boldsymbol{\Lambda}_c \mathbf{V}_c^\top (\mathbf{W}_c^{enc})^\top = (\mathbf{W}_c^{enc} \mathbf{V}_c \boldsymbol{\Lambda}_c^{\frac{1}{2}}) (\mathbf{W}_c^{enc} \mathbf{V}_c \boldsymbol{\Lambda}_c^{\frac{1}{2}})^\top \approx \mathbf{I}.$$

Пусть $\mathbf{R}_c = \mathbf{W}_c^{enc} \mathbf{V}_c \boldsymbol{\Lambda}_c^{\frac{1}{2}}$, тогда из предыдущего выражения следует, что $\mathbf{R}_c$ — ортогональна. Отсюда же:

$$\mathbf{W}_c^{enc} \mathbf{V}_c = \mathbf{R}_c \boldsymbol{\Lambda}_c^{-\frac{1}{2}} \Rightarrow \mathbf{W}_c^{enc} \approx \mathbf{R}_c \boldsymbol{\Lambda}_c^{-\frac{1}{2}} \mathbf{V}_c^\top.$$

Аналогично, параметры декодировщика выражаются как $\mathbf{W}_c^{dec} \approx \mathbf{V}_c \boldsymbol{\Lambda}_c^{\frac{1}{2}} \mathbf{R}_c^{-1}$.

Таким образом, ввиду ортогональности $\mathbf{V}_c$ и $\mathbf{R}_c$, сингулярные числа параметров зависят только от матрицы $\boldsymbol{\Lambda}_c$. Приведённые выше выражения для $\mathbf{W}_c^{enc}$ и $\mathbf{W}_c^{dec}$ являются сингулярным разложением. $(\lambda_i^c)^{-\frac{1}{2}}$ — сингулярные числа для энкодера и $(\lambda_i^c)^{\frac{1}{2}}$ — сингулярные числа для декодера.

Так как $\text{cov}(\mathbf{x}_c) = \mathbf{V}_c \mathbf{\Lambda}_c \mathbf{V}_c^\top$, то λ_i^c — это дисперсия входных данных вдоль направления i -го собственного вектора, то по лемме 1, λ_i^c для $c \in 1, 2$ сходятся к одному и тому же значению λ_i^c при увеличении m . Таким образом, сингулярные числа весов модели так же сходятся к одному значению для разных c :

$$\sigma_i^{\text{model}}(\mathbf{W}_c^{\text{enc}}) \xrightarrow{m \rightarrow \infty} \lambda_i^{-\frac{1}{2}}, \quad \sigma_i^{\text{model}}(\mathbf{W}_c^{\text{dec}}) \xrightarrow{m \rightarrow \infty} \lambda_i^{\frac{1}{2}}.$$

□

Функция потерь $\mathcal{L}(\psi_c)$ с добавлением регуляризационного члена $\|\text{cov}(\mathbf{h}_c) - \mathbf{I}\|^2$, декоррелирующего векторы $\mathbf{h}_c$ из скрытого пространства, делает модель автокодировщика по своим свойствам ближе к VAE, так как матрица ковариации скрытого представления принимает диагональный вид, характерный для модели VAE. Данное замечание позволяет использовать результаты теоремы 1 в качестве доказательства выполнимости гипотезы 3 как для моделей AE, так и VAE.

Теорема 1 доказана для частного случая моделей с полносвязными слоями без нелинейностей. Оценка выполнимости теоремы для нелинейного случая приведена экспериментально. Далее в работе представлена теорема, имеющая большее число ограничений на решаемую задачу, но включающая в рассмотрение модели с нелинейностями.

Теорема 1 характеризует поведение векторов автокодировщиков при сближении векторов выборок. Однако большая практическая польза заключается в возможности моделей описывать не сходства, а различия между наборами данных. В качестве базового свойства предлагается рассмотреть возможность различать модели, обученные на выборках данных, порождённых различными распределениями.

Пусть p_c — распределение данных класса $c \in \{1, 2\}$ на $\mathbb{R}^d$ с ковариацией $\Sigma_c := \Sigma_c(p_c) := \mathbb{E}_{\mathbf{x} \sim p_c}[\mathbf{x}\mathbf{x}^\top]$. Для выборки $\mathbf{X}_c = \{\mathbf{x}_i : \mathbf{x}_i \sim p_c\}_{i=1}^n$ размера n вводится эмпирическая ковариация $\hat{\Sigma}_c := \hat{\Sigma}_c(\mathbf{X}_c) := \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top$.

Рассматривается модель с параметрами $\psi \in \Psi$ и функцией потерь $\mathcal{L}(\psi; p_c) := -\mathbb{E}_{\mathbf{x} \sim p_c} [l_\psi(\mathbf{x})]$, где $l_\psi(\mathbf{x})$ — некоторый максимизируемый функционал.

В рамках данной работы предполагается, что функция потерь $\mathcal{L}(\psi; p_c)$ может быть выражена как функция от ковариации данных Σ_c , то есть существует функционал $\mathcal{L}_\Sigma$ такой, что $\mathcal{L}(\psi; p_c) = \mathcal{L}_\Sigma(\psi; \Sigma_c(p_c))$. Это выполняется, например, когда $l_\psi(\mathbf{x})$ зависит от $\mathbf{x}$ только через вторые моменты, либо когда распределение p_c полностью определяется своей ковариацией, как в гауссовом случае.

Для простоты обозначений далее используется запись $\mathcal{L}(\psi; \Sigma_c) := \mathcal{L}_\Sigma(\psi; \Sigma_c)$.

Пусть $\mathcal{L}(\psi; \Sigma_c)$ достигает минимума в $\psi^*(\cdot)$. На выборке $\mathbf{X}_c$ минимум достигается в $\hat{\psi}_n(\cdot)$:

$$\psi^*(\Sigma_c) := \arg \min_{\psi \in \Psi} \mathcal{L}(\psi; \Sigma_c), \quad \hat{\psi}_n(\hat{\Sigma}_c) := \arg \min_{\psi \in \Psi} \mathcal{L}_n(\psi; \hat{\Sigma}_c),$$

где $\mathcal{L}_n$ — эмпирическая функция потерь.

Для корректного изложения и доказательства последующих результатов необходимо ввести набор предпосылок, обеспечивающих гладкость, выпуклость и устойчивость оптимальных решений, а также ограниченность данных.

Условия выполнимости теоремы.

(B1) (**Гладкость**) $\mathcal{L}(\psi; \Sigma_c)$ принадлежит классу C^2 по ψ и C^1 по параметру ковариации Σ_c . Заметим, что проверка гладкости по Σ_c является трудновычислимой. Однако, для гауссовских распределений утверждение верно [12].

(B2) (**Локальная уникальность и сильная выпуклость**) Для каждого класса c существует окрестность U_c^{B2} ковариаций вокруг

Σ_c , задаваемая метрикой $\|\cdot\|_{op}$, такой что для всех $\Sigma \in U_c^{B2}$ функция $\psi \mapsto \mathcal{L}(\psi; \Sigma_c)$ имеет локально уникальный изолированный минимум $\psi^*(\Sigma)$ и гессиан в этой точке удовлетворяет: $\exists \hat{\mu} : \lambda_{\min}(\nabla_{\psi\psi}^2 \mathcal{L}(\psi^*(\Sigma); \Sigma_c)) \geq \hat{\mu} > 0$, где $\lambda_{\min}(\cdot)$ – наименьшее собственное число гессиана.

(B3) (**Дифференцируемость по Σ .**) Для каждого класса c существует окрестность U_c^{B3} ковариаций вокруг Σ_c , в которой семейство минимизаторов $\psi^*(\Sigma)$ является C^1 -функцией по Σ , то есть якобиан $J_\Sigma := \partial_\Sigma \psi^*(\Sigma)$ существует и непрерывен.

Далее для каждого класса рассматривается окрестность $U_c = U_c^{B2} \cap U_c^{B3}$, чтобы одновременно выполнялись оба требования (B2) и (B3). Так как это окрестности вокруг одной и той же точки Σ_c , то пересечение не пусто.

(B4) (**Ошибка аппроксимации**) Существует фиксированная окрестность $\mathcal{V}_c \subset \Psi$ и последовательность $\eta_n^c \xrightarrow{p} 0$ такие, что $\sup_{\psi \in \mathcal{V}_c} |\mathcal{L}_n(\psi; \hat{\Sigma}_c) - \mathcal{L}(\psi; \Sigma_c)| \leq \eta_n^c$, где n – размер выборки. Все рассматриваемые в теореме значения $\psi^*(\Sigma_c)$ лежат в $\mathcal{V}_c$. Для обобщения на все классы c в теореме используется последовательность, полученная поточечным максимумом $\eta_n := \max(\eta_n^1, \eta_n^2, \dots, \eta_n^c)$.

(B5) (**Ограниченность данных**) Предполагается, что существует константа $B > 0$ такая, что $\|\mathbf{x}_i\|_2 \leq B$ почти наверное для всех i . Данное свойство обеспечивает применение концентрационных неравенств для эмпирической ковариации, а на практике достигается предварительной обработкой данных — клиппингом или винсоризацией.

(B6) (**Различие первых r сингулярных чисел**) Пусть первые r сингулярных чисел матрицы параметров $\psi^*(\Sigma_c)$ различные и отделены от остальных на $\delta_r > 0$.

Теорема 2. Пусть выполнены предпосылки (B1)-(B6). Вводится обозначение: $\Delta_r := \|\sigma_{1:r}^{data}(\mathbf{X}_1) - \sigma_{1:r}^{data}(\mathbf{X}_2)\|_2$, где $\sigma_{1:r}^{data}(\cdot)$ — сингулярные числа векторов данных $\mathbf{X}_c$ с первого по r -ый.

Тогда существуют константы $C_0 > 0$ и $c_* > 0$ такие, что для любого $\delta \in (0; \frac{1}{2})$ при размере выборки n выполнено с вероятностью не менее $1 - 2\delta$:

$$\begin{aligned} \|\sigma_{1:r}^{model}(\hat{\psi}_n(\hat{\Sigma}_1)) - \sigma_{1:r}^{model}(\hat{\psi}_n(\hat{\Sigma}_2))\|_2 \\ \geq c_* \Delta_r - C_0 \left(\sqrt{\frac{\log(1/\delta)}{n^2}} + \sqrt{\eta_n} + \tau_n \right), \end{aligned}$$

где $\tau_n := \max(\tau_n^1, \tau_n^2)$ — максимум из погрешностей оптимизации для моделей на выборках объема n , обученных на $\mathbf{X}_1, \mathbf{X}_2$. В частности, если $\Delta_r > 0$ и $\eta_n, \tau_n \rightarrow 0$, то при $n \rightarrow \infty$ правая часть остается положительной, и векторы первых r сингулярных чисел расходятся с ненулевым зазором с вероятностью, стремящейся к 1.

Доказательство. Шаг 1. Концентрация ковариаций.

При условии выполнения (B5) утверждается, что выполнено неравенство Хёффдинга [14] для независимых, почти достоверно ограниченных $\mathbf{x}_i \mathbf{x}_i^\top$, порождённых распределением p_c : $\exists B : \mathbb{P}(\|\mathbf{x}_i \mathbf{x}_i^\top\|_2 \leq B) = 1$, выполнено:

$$\mathbb{P} \left(\left\| \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i \mathbf{x}_i^\top - \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^\top]) \right\|_{op} \geq \varepsilon \right) \leq 2 \exp \left(-\frac{n^2 \varepsilon^2}{2B^2} \right).$$

Таким образом, при переходе к Σ_c :

$$\mathbb{P}(\|\hat{\Sigma}_c - \Sigma_c\|_{op} \geq \varepsilon) \leq 2 \exp \left(-\frac{n^2 \varepsilon^2}{2B^2} \right).$$

Случаи для $c = 1, 2$ объединены для одновременного выполнения оценки:

$$\begin{aligned} \mathbb{P}\left(\bigcup_{c=1}^2 \{\|\hat{\Sigma}_c - \Sigma_c\|_{op} \geq \varepsilon\}\right) &\leq \sum_{c=1}^2 \mathbb{P}\left(\|\hat{\Sigma}_c - \Sigma_c\|_{op} \geq \varepsilon\right) \\ &\leq 2 \exp\left(-\frac{n^2 \varepsilon^2}{2B^2}\right) \leq \delta. \end{aligned}$$

Откуда δ можно выразить следующим образом:

$$\frac{n^2 \varepsilon^2}{2B^2} \geq \log\left(\frac{4}{\delta}\right) \Rightarrow \varepsilon \geq B \sqrt{\frac{2}{n^2} \log\left(\frac{4}{\delta}\right)}.$$

Следовательно, можно ввести обозначение: $\varepsilon_n(\delta) := C \sqrt{\frac{\log(1/\delta)}{n^2}}$, где $C = \sqrt{2}B$.

Таким образом, для каждого класса c выполнено $\mathbb{P}\left(\|\hat{\Sigma}_c - \Sigma_c\|_{op} \leq \varepsilon_n(\delta)\right) \geq 1 - \delta$.

Шаг 2. Оценка ошибки параметров.

По (B2) гессиан в точке минимума удовлетворяет $\nabla_{\psi\psi}^2 \mathcal{L}(\psi^*(\Sigma_c); \Sigma_c) \succeq \hat{\mu} \mathbf{I}$, где $\hat{\mu}$ можно считать константой сильной выпуклости. Следовательно, функцию потерь для $\psi(\Sigma_c)$ в малой окрестности можно оценить снизу квадратичной функцией от $\psi(\Sigma_c)$:

$$\mathcal{L}(\psi(\Sigma_c); \Sigma_c) - \mathcal{L}(\psi^*(\Sigma_c); \Sigma_c) \geq \frac{\hat{\mu}}{2} \|\psi(\Sigma_c) - \psi^*(\Sigma_c)\|_2^2. \quad (3)$$

Далее, для простоты записи на этом шаге опущены зависимости $\mathcal{L}$ и ψ от Σ_c в обозначениях. При добавлении и вычитании эмпирической функции потерь $\mathcal{L}_n$:

$$\begin{aligned} \mathcal{L}(\hat{\psi}_n) - \mathcal{L}(\psi^*) &= [\mathcal{L}(\hat{\psi}_n) - \mathcal{L}_n(\hat{\psi}_n)] \\ &\quad + [\mathcal{L}_n(\hat{\psi}_n) - \mathcal{L}_n(\psi^*)] \\ &\quad + [\mathcal{L}_n(\psi^*) - \mathcal{L}(\psi^*)]. \end{aligned} \quad (4)$$

Так как по определению $\psi^*(\Sigma)$ и $\hat{\psi}_n(\hat{\Sigma})$:

$$\psi^*(\Sigma_c) := \arg \min_{\psi \in \Psi} \mathcal{L}(\psi; \Sigma_c), \quad \hat{\psi}_n(\hat{\Sigma}_c) := \arg \min_{\psi \in \Psi} \mathcal{L}_n(\psi; \hat{\Sigma}_c),$$

то слагаемые из выражения 4 являются: $\mathcal{L}(\hat{\psi}_n) - \mathcal{L}_n(\hat{\psi}_n)$ — ошибка аппроксимации в точке $\hat{\psi}_n$, $\mathcal{L}_n(\hat{\psi}_n) - \mathcal{L}_n(\hat{\psi}^*) \leq 0$, так как $\hat{\psi}_n$ минимизирует $\mathcal{L}_n$, $\mathcal{L}_n(\hat{\psi}^*) - \mathcal{L}(\psi^*)$ — ошибка аппроксимации в точке ψ^* .

Поскольку второе слагаемое неположительно:

$$\mathcal{L}(\hat{\psi}_n) - \mathcal{L}(\psi^*) \leq [\mathcal{L}(\hat{\psi}_n) - \mathcal{L}_n(\hat{\psi}_n)] + [\mathcal{L}_n(\psi^*) - \mathcal{L}(\psi^*)].$$

Оба оставшихся слагаемых ограничены сверху равномерной ошибкой:

$$|\mathcal{L}(\psi) - \mathcal{L}_n(\psi)| \leq \sup_{\psi \in \mathcal{V}} |\mathcal{L}(\psi) - \mathcal{L}_n(\psi)| = \eta_n.$$

Таким образом, при условии квадратичного роста (3):

$$\frac{\hat{\mu}}{2} \|\hat{\psi}_n - \psi^*\|_2^2 \leq |\mathcal{L}(\hat{\psi}_n) - \mathcal{L}(\psi^*)| \leq 2\eta_n.$$

Тогда норма разности эмпирических и идеальных параметров:

$$\|\hat{\psi}_n(\hat{\Sigma}_c) - \psi^*(\hat{\Sigma}_c)\|_2 \leq \frac{2}{\sqrt{\hat{\mu}}} \sqrt{\eta_n}.$$

Если алгоритм возвращает приближённый минимум с оптимизационной ошибкой τ_n (точнее: $\mathcal{L}_n(\hat{\psi}_n) - \inf_{\psi} \mathcal{L}_n(\psi) \leq \tau_n$), то эта погрешность добавляется аддитивно:

$$\|\hat{\psi}_n(\hat{\Sigma}_c) - \psi^*(\hat{\Sigma}_c)\|_2 \leq C_{\text{opt}}(\sqrt{\eta_n} + \tau_n),$$

где можно взять $C_{\text{opt}} = C'/\hat{\mu}$ с некоторой C' , зависящей от локальной формы функции потерь.

Шаг 3. Би-Липшицевость $\psi^* \mapsto \sigma_{1:r}^{model}(\psi^*)$

Так как первые r сингулярные числа $\sigma_1^{model}(\psi^*), \dots, \sigma_r^{model}(\psi^*)$ различны по (В6), то по стандартной теории чувствительности SVD [27] ограничение отображения $\psi^* \mapsto \sigma_{1:r}^{model}(\psi^*)$ на класс матриц с разделёнными первыми r сингулярными числами является би-Липшицевым с константами $\kappa_{\sigma, \min}, \kappa_{\sigma, \max}$:

$$\begin{aligned} \kappa_{\sigma, \min} \|\psi_1^* - \psi_2^*\|_2 &\leq \|\sigma_{1:r}^{model}(\psi_1^*) - \sigma_{1:r}^{model}(\psi_2^*)\|_2 \\ &\leq \kappa_{\sigma, \max} \|\psi_1^* - \psi_2^*\|_2. \end{aligned}$$

Шаг 4. Би-Липшицевость $\Sigma_c \mapsto \sigma_{1:r}^{model}(\psi^*(\Sigma_c))$

Сначала используется би-Липшицевость отображения $\Sigma_c \mapsto \psi^*(\Sigma_c)$, что следует из (В3), опираясь на (В1)+(В2) как технические условия для теоремы о неявной функции. Вводятся обозначения для констант би-Липшицевости $\kappa_{\Sigma, \min}, \kappa_{\Sigma, \max}$:

$$\begin{aligned} \kappa_{\Sigma, \min} \|\Sigma_1 - \Sigma_2\|_{op} &\leq \|\psi^*(\Sigma_1) - \psi^*(\Sigma_2)\|_2 \\ &\leq \kappa_{\Sigma, \max} \|\Sigma_1 - \Sigma_2\|_{op}. \end{aligned}$$

Далее применяется шаг 3 к отображению $\psi^* \mapsto \sigma_{1:r}^{model}(\psi^*)$. В результате получается комбинированную би-Липшицевость для отображения $\Sigma_c \mapsto \sigma_{1:r}^{model}(\psi^*(\Sigma_c))$ с константами $\kappa_{\min} := \kappa_{\sigma, \min} \cdot \kappa_{\Sigma, \min}$, $\kappa_{\max} := \kappa_{\sigma, \max} \cdot \kappa_{\Sigma, \max}$, и, следовательно:

$$\begin{aligned} \kappa_{\min} \|\Sigma_1 - \Sigma_2\|_{op} &\leq \|\sigma_{1:r}^{model}(\psi^*(\Sigma_1)) - \sigma_{1:r}^{model}(\psi^*(\Sigma_2))\|_2 \\ &\leq \kappa_{\max} \|\Sigma_1 - \Sigma_2\|_{op}. \end{aligned}$$

Шаг 5. (Оценка погрешностей и неравенство треугольника).

Для краткости записи вводятся следующие сокращения: $\hat{\psi}_c := \hat{\psi}_n(\hat{\Sigma}_c)$, $\psi_c^* := \psi^*(\Sigma_c)$, $\psi_{\hat{c}}^* := \psi^*(\hat{\Sigma}_c)$.

Из Шага 2 можно записать оценку ошибки параметров $\|\hat{\psi}_c - \psi_c^*\|_2 \leq C_{\text{opt}}(\sqrt{\eta_n} + \tau_n)$, где C_{opt} зависит только от $\hat{\mu}$ и локальной геометрии $\mathcal{L}$.

По Шагу 4 отображение $\Sigma_c \mapsto \psi^*(\Sigma_c)$ является Липшицевым с константой $\kappa_{\Sigma, \max}$, откуда, с учётом Шага 1:

$$\|\psi_{\hat{c}}^* - \psi_c^*\|_2 \leq \kappa_{\Sigma, \max} \|\hat{\Sigma}_c - \Sigma_c\|_{op} \leq \kappa_{\Sigma, \max} \varepsilon_n(\delta).$$

Теперь применяется неравенство треугольника к векторам из первых r сингулярных чисел:

$$\begin{aligned} \|\sigma_{1:r}^{\text{model}}(\hat{\psi}_1) - \sigma_{1:r}^{\text{model}}(\hat{\psi}_2)\|_2 &\geq \|\sigma_{1:r}^{\text{model}}(\psi_1^*) - \sigma_{1:r}^{\text{model}}(\psi_2^*)\|_2 \\ &\quad - \|\sigma_{1:r}^{\text{model}}(\hat{\psi}_1) - \sigma_{1:r}^{\text{model}}(\psi_1^*)\|_2 \\ &\quad - \|\sigma_{1:r}^{\text{model}}(\hat{\psi}_2) - \sigma_{1:r}^{\text{model}}(\psi_2^*)\|_2. \end{aligned}$$

Для каждого $c \in \{1, 2\}$:

$$\begin{aligned} &\|\sigma_{1:r}^{\text{model}}(\hat{\psi}_c) - \sigma_{1:r}^{\text{model}}(\psi_c^*)\|_2 \\ &\leq \|\sigma_{1:r}^{\text{model}}(\hat{\psi}_c) - \sigma_{1:r}^{\text{model}}(\psi_{\hat{c}}^*)\|_2 + \|\sigma_{1:r}(\psi_{\hat{c}}^*) - \sigma_{1:r}(\psi_c^*)\|_2 \\ &\leq \kappa_{\sigma, \max} \|\hat{\psi}_c - \psi_{\hat{c}}^*\|_2 + \kappa_{\sigma, \max} \|\psi_{\hat{c}}^* - \psi_c^*\|_2 \\ &\leq \kappa_{\sigma, \max} \left(C_{\text{opt}}(\sqrt{\eta_n} + \tau_n) + \kappa_{\Sigma, \max} \varepsilon_n(\delta) \right). \end{aligned}$$

Следовательно,

$$\begin{aligned} \|\sigma_{1:r}^{\text{model}}(\hat{\psi}_1) - \sigma_{1:r}^{\text{model}}(\hat{\psi}_2)\|_2 &\geq \|\sigma_{1:r}^{\text{model}}(\psi_1^*) - \sigma_{1:r}^{\text{model}}(\psi_2^*)\|_2 \\ &\quad - 2\kappa_{\sigma, \max} \left(C_{\text{opt}}(\sqrt{\eta_n} + \tau_n) + \kappa_{\Sigma, \max} \varepsilon_n(\delta) \right). \end{aligned}$$

Шаг 6. Переход к Δ_r и итоговая оценка.

По Шагу 4 комбинированная би-Липшицевость даёт

$$\|\sigma_{1:r}^{\text{model}}(\psi_1^*) - \sigma_{1:r}^{\text{model}}(\psi_2^*)\|_2 \geq \kappa_{\min} \|\Sigma_1 - \Sigma_2\|_{op}.$$

По неравенству Вейля [28] выполнено: $\|\Sigma_1 - \Sigma_2\|_{op} \geq \frac{1}{\sqrt{r}}\Delta_r$, где Δ_r — разность первых r собственных значений. Следовательно,

$$\begin{aligned} & \|\sigma_{1:r}^{model}(\hat{\psi}_1) - \sigma_{1:r}^{model}(\hat{\psi}_2)\|_2 \\ & \geq \frac{\varkappa_{\min}}{\sqrt{r}}\Delta_r - 2\varkappa_{\sigma, \max} \left(C_{\text{opt}}(\sqrt{\eta_n} + \tau_n) + \varkappa_{\Sigma, \max}\varepsilon_n(\delta) \right). \end{aligned}$$

Для краткости вводятся новые обозначения для констант:

$$c_* := \frac{\varkappa_{\min}}{\sqrt{r}}, \quad C_0 := 2\varkappa_{\sigma, \max} \max\{C_{\text{opt}}, \varkappa_{\Sigma, \max}\},$$

получаем с вероятностью $\geq 1 - 2\delta$:

$$\boxed{\|\sigma_{1:r}^{model}(\hat{\psi}_1) - \sigma_{1:r}^{model}(\hat{\psi}_2)\|_2 \geq c_*\Delta_r - C_0(\sqrt{\eta_n} + \tau_n + \varepsilon_n(\delta)).}$$

Если $\Delta_r > 0$ и $\eta_n, \tau_n, \varepsilon_n(\delta) \rightarrow 0$ при $n \rightarrow \infty$, то правая часть остаётся положительной для достаточно больших n , и первые r сингулярных чисел эмпирических минимизаторов $\hat{\psi}_n(\hat{\Sigma}_1)$ и $\hat{\psi}_n(\hat{\Sigma}_2)$ различимы с вероятностью, стремящейся к 1. $\square$

Данный результат демонстрирует, что вектор порождающей модели содержит достаточно информации о распределении исходных данных. Более того, такие представления могут обладать структурой, отражающей смещение выборок и возможности их линейной разделимости.

В случае модели VAE функционал $l_\psi(\mathbf{x})$ представляет собой ELBO, которое обладает всеми необходимыми свойствами для выполнения условий теоремы. Таким образом, приведенные рассуждения применимы для VAE-подобных архитектур.

4 Вычислительный эксперимент

Для подтверждения полученных теоретических результатов были проведены эксперименты на наборах данных CIFAR-10 и FashionMNIST. Ниже приведены детальное описание методики, конфигурации моделей, результаты экспериментов и их связь с доказанными теоремами.

4.1 Методика и настройки

Для экспериментов на CIFAR-10 выбирались наиболее различные классы. Для объектов каждого класса с помощью предобученной модели ResNet50 [13] были вычислены эмбединги. Затем вычислялось среднее расстояние между векторами разных классов в евклидовом пространстве. Три класса с наибольшим расстоянием друг от друга затем использовались в эксперименте: 5 — собаки, 6 — лягушки, 8 — корабли.

В качестве базовой модели использовался автокодировщик (AE) и вариационный автокодировщик (VAE) с одним-двумя полносвязными слоями в кодировщике и декодировщике как в комбинации с нелинейной функцией активации, так и без нее. Скрытое пространство размера 256. Все слои инициализировались стандартно и обучались оптимизатором AdamW с шагом обучения 10^{-3} и размером батча 32. Каждая модель обучается в течение 20 эпох. Для стабильности и статистической значимости результатов эксперименты выполнялись $N = 5$ раз с различными случайными подвыборками. Для ряда оценок приводится среднее значение и стандартное отклонение.

Для каждой обученной модели вычислялось векторное представление по описанному ранее алгоритму. Константа r из алгоритма выбиралась так, чтобы оставленные в векторе сингулярные числа составляли 80% от суммы всех сингулярных чисел параметров модели. Классификация проводилась с использованием логистической регрессии с L_2 -регуляризацией, обучаемой на векторах моделей. Целевой переменной являлся класс данных, на которых был обучен соответствующий автокодировщик. Для оценки качества

классификации использовались метрики Accuracy, Average Precision и ROC AUC.

Здесь и далее классы из наборов данных CIFAR-10 или FashionMnist подразумеваются как две различные выборки, каждая из которых порождена из своего распределения p_c . Класс выборки c — это класс изображений, определённый в исходном наборе данных.

4.2 Базовый эксперимент (два класса)

В базовом эксперименте выбирались три максимально различающихся класса из CIFAR-10. Из первых двух классов семплировались подвыборки фиксированного размера n . Здесь и далее $n = 2000$, если не оговорено иное. На каждой подвыборке обучался AE/VAE с вышеописанной архитектурой, затем модели векторизовались по описанному ранее алгоритму, и на векторах обучалась логистическая регрессия для бинарной классификации.

Иллюстрация архитектуры эксперимента приведена на рис. 2. Accuracy определения логистической регрессией класса выборки из CIFAR-10 для AE с 2 полносвязными слоями в кодировщике и декодировщике и нелинейными функциями активации составляет $0.98(\pm 0.02)$; для VAE — $0.97(\pm 0.03)$; для AE с 1 полносвязным слоем в кодировщике и декодировщике и без нелинейных функций активации — $0.99(\pm 0.01)$.

Выводы. Метрики логистической регрессии для задачи определения класса выборки, на которой были обучены AE/VAE, близки к 1. Следовательно, вектор сингулярных чисел модели содержит в себе достаточно информации о статистических признаках обучающей выборки. Эксперимент проведён для моделей с нелинейностями и без них. В обоих случаях результаты аналогичны.




Рис. 2: Схема эксперимента с обучением множества автокодировщиков на подвыборках двух классов и последующей классификацией их векторных представлений

4.3 Эксперимент с подмешиванием третьего класса

В следующем эксперименте проверялась способность векторов сингулярных чисел моделей отображать смещение обучающих выборок. В тесте выбирались $\mathbf{X}_c$ и $c \in \{1, 2\}$ как наборы объектов из двух заранее выбранных классов CIFAR-10 или Fashion-MNIST аналогично предыдущему эксперименту. После чего к ним с различной долей α подмешивался третий класс $\mathbf{X}_3$. Для фиксированного набора параметров модели варьировалась α в диапазоне от 0.6 до 0.99, и для каждого значения α формировались новые подвыборки, на которых обучались автокодировщики. Затем по векторным представлениям оценивалось качество бинарной классификации. Оценивалась точность логистической регрессии в определении класса $c \in \{1, 2\}$, на котором обучалась векторизованная модель.


На Рис. 3 представлена наглядная зависимость качества классификации от доли $\mathbf{X}_3$ в обучающей выборке. Для неё характерно резкое убывание метрик при увеличении α : небольшое число векторов третьего класса (малые α) в выборках почти не влияет на разделимость, то есть метрики качества

на графиках на Рис. 3 близки к 1; тогда как при больших α классификатор векторов моделей начинает допускать больше ошибок, так как распределения обучающих данных моделей начинают приближаться к распределению $\mathbf{X}_3$, что схематично представлено на Рис. 1.


В качестве расширения эксперимента использовались различные способы семплирования третьего класса для подмешивания в $\mathbf{X}_1$ и $\mathbf{X}_2$: для каждого α подвыборка семплировалась для каждого из $2N$ автокодировщиков случайно и независимо (Различные подвыборки класса 3 на рис. 3); для каждого α подвыборка третьего класса семплировалась единожды и добавлялась одинаково для всех $2N$ моделей (Одинаковые подвыборки класса 3 (езде) на рис. 3); в третьем подходе для каждого α по одному из N автокодировщиков каждого основного класса обучалось на выборках с одинаковой примесью из третьего класса (Одинаковые подвыборки класса 3 (пары) на рис. 3).

Эксперимент проводился на двух наборах данных: CIFAR10 и FashionMNIST. Можно заметить различия для этих наборов в величине доли третьего класса, при которой начинает существенно ухудшаться качество логистической регрессии в задаче определения обучающей выборки для модели. Объяснение этому наблюдению дано в следующих экспериментах и связано с изначальной близостью классов, выбранных для обучения.


Выводы. Предложенный метод векторизации моделей чувствителен к смещениям выборок: при невысоких долях постороннего класса (малые α) представления моделей, обученных на подвыборках из различных классов, разделимы с высокой точностью, что показано на графиках Рис. 3. При больших α представления моделей, обученных на смеси $\mathbf{X}_c$ и $\mathbf{X}_3$ смещаются для $c \in \{1, 2\}$, и классификатор начинает различать их тем хуже, чем больше α . Это демонстрирует, что пространство векторных представлений отражает непрерывные переходы между распределениями данных. Эксперимент проведён для случая автокодировщиков без нелинейностей и с нелинейными функциями активаций. Во всех вариантах модели ведут себя



(а) CIFAR10, АЕ с 2 полносвязными слоями в кодировщике и декодировщике и нелинейными функциями активации



(б) CIFAR10, АЕ с 1 полносвязным слоем в кодировщике и декодировщике без нелинейностей (только для случая различных подвыборок из класса 3)



(в) FashionMNIST, АЕ с 2 полносвязными слоями в кодировщике и декодировщике и нелинейными функциями активации (только для случая различных подвыборок из класса 3)

Рис. 3: Демонстрация качества работы логистической регрессии на векторах автокодировщиков при различной доле подмешиваемого третьего класса в обучающей выборке моделей

схожим образом: при увеличении α качество классификации обучающей выборки по вектору модели падает.

4.4 Эксперимент с добавлением случайных объектов

В данном эксперименте $\mathbf{X}_3$ включает в себя не один конкретный класс набора данных CIFAR-10, а любой объект, не принадлежащий классам, из которых выбраны $\mathbf{X}_c$, $c \in \{1, 2\}$. Таким образом, предыдущий эксперимент расширяется до использования «шумовой» примеси. Такой тип шума имитирует реальную ситуацию, когда в выборке присутствуют выбросы или примеси неизвестного происхождения. Методика повторяет предыдущую: варьировалась доля шумовых объектов, семплировались новые выборки $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$, на них обучались модели, по которым строились вектора сингулярных чисел и оценивалось качество классификации с помощью логистической регрессии.




Рис. 4: Демонстрация влияния примешивания различного шума на качество классификации моделей. Примесь только класса 3: $\mathbf{X}_3$ семплируется только из одного класса; Примесь из классов 3 и 4 — из двух; Примесь из всего набора данных — из всех классов CIFAR-10, кроме использованных в $\mathbf{X}_1, \mathbf{X}_2$.

Выводы. Добавление случайных объектов $\mathbf{X}_3$ снижает разделимость (Рис. 1) векторов моделей, обученных на смесях $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$. Несмотря на небольшую итоговую разницу в точности, подмешивание шумовых объектов все же сильнее влияет на качество разделения, что видно по жёлтому графику

на Рис. 4. В предыдущем эксперименте подмешивались векторы только из одного определённого класса. Результаты данного эксперимента подтверждают лемму 1 и теорему 1. В частности, чем больше отличие шума от $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$, тем быстрее падает качество при увеличении доли шума.

4.5 Корреляция с сингулярными числами выборки

В данном эксперименте анализируется зависимость сближения векторов сингулярных чисел весов моделей, и векторов сингулярных чисел данных от доли подмешанных объектов нового класса. Теоретическое сближение векторов описывалось для частного случая с полносвязными слоями без нелинейности в теореме 1. Взяты три класса из выборки Fashion MNIST. Из первых двух классов семплировались векторы для $\mathbf{X}_1, \mathbf{X}_2$. Третий класс выступал в качестве подмешиваемой выборки $\mathbf{X}_3$. Итоговые выборки $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$ получались путём семплирования $(1 - \alpha)n$ элементов из $\mathbf{X}_1, \mathbf{X}_2$, соответственно, и αn элементов из $\mathbf{X}_3$, где $n = 2000$. Затем для значений α от 0.6 до 0.99 вычислялся вектор сингулярных чисел для каждой из выборок $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$. Между полученными векторами вычислялось среднее абсолютное расстояние для $N = 100$ различных выборок $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$.

Во второй части эксперимента на $\tilde{\mathbf{X}}_1, \tilde{\mathbf{X}}_2$ обучались вариационные автокодировщики в количестве $N = 100$ для каждого класса. Затем подсчитывались векторы сингулярных чисел параметров, полученных из обученных моделей VAE. Для VAE, обученных на выборках, соответствующих различным первоначальным классам, рассматривалось среднее абсолютное расстояние между их векторами при различных значениях α .

Среднее абсолютное расстояние для первой и второй части эксперимента отображалось на рис. 5 по оси Y и по оси X соответственно.

Выводы. На Рис. 5 видна линейная зависимость между средним абсолютным расстоянием для векторов сингулярных чисел выборки и векторов




Рис. 5: Сравнение MAE между векторами выборок и моделей. Ось X – разность между векторами моделей, ось Y – разность между векторами данных. Каждая точка соответствует своему α – доле третьего класса в обучающей выборке.

сингулярных чисел моделей. Согласно статистическому тесту с использованием корреляции Пирсона линейная зависимость статистически значима.

4.6 Попарные сравнения (каждый класс против каждого)

В качестве расширения базового эксперимента было проведено сравнение «каждый класс против каждого». В нём для всех пар классов FashionMNIST выполнялись процедуры, аналогичные базовому эксперименту: образование подвыборок $\mathbf{X}_1$, $\mathbf{X}_2$ без примесей, обучение множества АЕ с 2 полносвязными слоями и нелинейными функциями активации, векторизация и обучение

бинарного классификатора. Результаты усреднялись и визуализировались в виде матрицы попарной разделимости на Рис. 6.

	T-shirt/Top	Trouser	Pullover	Dress	Coat	Sandals	Shirt	Sneaker	Bag	Ankle	Boots
T-shirt/Top	1.00	0.00	0.02	0.02	0.00	0.00	0.05	0.00	0.00	0.00	0.00
Trouser	1.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Pullover	0.95	1.00	1.00	0.02	0.01	0.00	0.01	0.00	0.00	0.00	0.00
Dress	0.93	1.00	0.94	1.00	0.02	0.00	0.02	0.01	0.00	0.00	0.02
Coat	1.00	1.00	0.97	0.93	1.00	0.00	0.02	0.00	0.00	0.00	0.00
Sandals	1.00	1.00	1.00	1.00	1.00	1.00	0.03	0.00	0.00	0.00	0.00
Shirt	0.85	1.00	0.97	0.94	0.93	0.93	1.00	0.00	0.00	0.00	0.00
Sneaker	1.00	1.00	1.00	0.97	1.00	1.00	1.00	1.00	0.00	0.00	0.00
Bag	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	0.00	0.00
Ankle Boots	1.00	1.00	1.00	0.95	1.00	1.00	1.00	1.00	1.00	1.00	1.00

Рис. 6: Демонстрация влияния примешивания различного шума на качество классификации моделей: нижняя треугольная матрица — среднее качество логистической регрессии в эксперименте разделения векторов моделей, верхняя треугольная матрица — среднее отклонение качества логистической регрессии, диагональ — среднее качество логистической регрессии в эксперименте one-vs-rest.

Выводы. Полученная попарная матрица показывает широкий спектр разделимости: некоторые пары классов (например, «пальто» против «платье») дают почти идеальные классификации на векторах сингулярных чисел моделей. Другие пары, например, визуально близкие классы, сложнее отличить друг от друга. Поэтому результаты логистической регрессии для этих пар сравнительно низкие. Наблюдения соответствуют ожиданиям: чем сильнее различие статистик исходных классов, тем более выражен сигнал в сингулярных спектрах параметров автокодировщика.

4.7 Вывод из экспериментов

Во всех сериях экспериментов подтверждена ключевая гипотеза: вектор сингулярных чисел параметров автокодировщика содержит информативный сигнал о распределении обучающих данных как в случае наличия

нелинейной функции активации, так и без нее. Для статистически сильно различных классов классификатор на таких векторах показывает почти идеальную разделимость, что подтверждается выводами из теоремы 2. При смещении классов и добавлении шума наблюдается предсказуемое ухудшение качества, что говорит о том, что пространство векторных представлений корректно отражает статистические сдвиги в данных.

5 Заключение

В ходе работы было показано, что даже при использовании простой архитектуры автокодировщика — по одному-двум полносвязным слоям в кодировщике и декодировщике и минималистичного подхода к построению признакового описания с помощью векторов сингулярных чисел параметры обученных моделей позволяют почти идеально различать выборки, между которыми существуют значимые различия в спектрах сингулярных чисел их ковариационных матриц. Этот результат особенно примечателен тем, что он достигается без привлечения сложных архитектур, предварительно обученных моделей или эвристических методов вычисления статистик входных данных.

Таким образом, обученная нейронная сеть может рассматриваться как универсальное средство описания выборки одним вектором, который формируется исключительно на основе её параметров. В отличие от традиционных подходов, основывающихся на специально подобранных статистических признаках или гистограммах данных, здесь информативное представление возникает как побочный продукт процесса обучения.

Проведённые эксперименты — от сравнения пар классов до анализа смесей и добавления шумовых объектов — показали, что пространство таких векторов адекватно отражает степень различия между наборами данных и чувствительно к их искажениям. Это открывает возможность применения подхода в задачах поиска и сравнения выборок, анализа смещений и

автоматической категоризации, при этом без необходимости хранения или прямого доступа к самим данным.

Перспективным направлением развития является изучение наблюдаемого эффекта с помощью других подходов и анализ их качества работы на различных архитектурах с разной глубиной и сложностью.

Список литературы

- [1] ЛАГОВСКИЙ Б. А., РУБИНОВИЧ Е. Я., ЮРЧЕНКОВ И. А. *Решение задачи сверхразрешения с использованием модели нейронной сети прямого распространения* // Управление большими системами. – 2023. – Т. 106. – С. 52–70.
- [2] САРАЕВ П. В. *Нелинейный метод наименьших квадратов и блочные рекуррентно-итерационные процедуры в обучении нейронных сетей* // Управление большими системами. – 2010. – Т. 30. – С. 24–34.
- [3] ACHILLE A., SOATTO S. *Information Dropout: learning optimal representations through noisy computation* // IEEE Transactions on Pattern Analysis and Machine Intelligence. – 2018. – Vol. 40, No. 12. – P. 2897–2905.
- [4] ADILOVA L., GEIGER B. C. *Information plane analysis for dropout neural networks* // arXiv – 01.03.2023. – URL: <https://arxiv.org/abs/2303.00596> (дата обращения: 18.10.25).
- [5] AKHAURI Y., ABDELFATTAH M. S. *Encodings for Prediction-based Neural Architecture Search* // arXiv – 04.03.2024. – URL: <https://arxiv.org/abs/2403.02484> (дата обращения: 10.08.25).
- [6] ALAIN G., BENGIO Y. *What Regularized Auto-Encoders Learn from the Data-Generating Distribution* // The Journal of Machine Learning Research. – 2014. – Vol. 15, No. 1. – P. 3563–3593.
- [7] ALET F., LOZANO-PEREZ T., KAEHLBLING L.P. *Modular Meta-Learning* // 2nd Conference on Robot Learning (CoRL), Zurich, Switzerland, October 29–31, 2018, Proceedings. – 2018.
- [8] ARPIT D., JASTRZEBSKI S., BALLAS N., KRUEGER D., BENGIO Y. *A closer look at memorization in deep networks* // The 34th International Conference on Machine Learning (ICML), Sydney, Australia, August 6–11, 2017, Proceedings. – 2017. – P. 233–242.
- [9] CHENG H., ZHANG M., QINFENG J. *A Survey on Deep Neural Network Pruning: Taxonomy, Comparison, Analysis, and Recommendations* // IEEE

- Transactions on Pattern Analysis and Machine Intelligence. – 2024. – Vol. 46, No 12. – P. 10558–10578.
- [10] CUI W., WU T., CRESSWELL J. C., SUI Y., GOLESTAN K. *DRESS: Disentangled Representation-based Self-Supervised Meta-Learning for Diverse Tasks* // arXiv. – 12.03.2025. – URL: <https://arxiv.org/abs/2503.09679v1> (дата обращения: 12.10.25).
- [11] ELSKEN T., METZEN J. H., HUTTER F. *Neural Architecture Search: A Survey* // Journal of Machine Learning Research. – 2019. – Vol. 20, No. 55. – P. 1–21.
- [12] DRTON M., XIAO H. *Smoothness of Gaussian conditional independence models* // arXiv – 28.09.2009. – URL: <https://arxiv.org/abs/0910.5447> (дата обращения: 10.08.25).
- [13] HE K., ZHANG X., REN S., SUN J. *Deep Residual Learning for Image Recognition* // 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, USA, June 27–30, 2016. – 2016. – P.770–778.
- [14] HOEFFDING W. *Probability Inequalities for Sums of Bounded Random Variables* // Journal of the American Statistical Association. – 1963. – Vol. 58, No. 301. – P. 13–30.
- [15] ILHARCO G., GURURANGAN S., WALLACE E., SHANKAR V., ROBERTS A., BOWMAN S. R., SCHMIDT L., HAJISHIRZI H. *Editing Models with Task Arithmetic* // The 36th Conference on Neural Information Processing Systems (NeurIPS), New Orleans, USA, November 28 to December 9, 2022, Proceedings. – 2022.
- [16] JOMAA H. S., SCHMIDT-THIEME L., GRABOCKA J. *Dataset2Vec: Learning Dataset Meta-Features* // Data Mining and Knowledge Discovery. – 2021. – Vol. 35, No. 3. – P. 964–985.
- [17] KINGMA D. P., WELLING M. *Auto-Encoding Variational Bayes* // arXiv – 10.12.2022. – URL: <https://arxiv.org/abs/1312.6114> (дата обращения:

18.10.25).

- [18] KRIZHEVSKY A. *Learning Multiple Layers of Features from Tiny Images* // M.: University of Toronto, 2009. – 60 с.
- [19] KLABUNDE M., SCHUMACHER T., STROHMAIER M., LEMMERICH F. *Similarity of Neural Network Models: A Survey of Functional and Representational Measures* // ACM Computing Surveys. – Vol. 57, No. 9. – 2025.
- [20] NEYSHABUR B., LI Z., BHOJANAPALLI S., LECUN Y., SREBRO N. *The role of over-parametrization in generalization of neural networks* // International Conference on Learning Representations, New Orleans, USA, May 6–7, 2019, Proceedings. – 2019.
- [21] REFINETTI M., GOLDT S. *The dynamics of representation learning in shallow, non-linear autoencoders* // Journal of Statistical Mechanics: Theory and Experiment. – 2023.
- [22] RAGHU M., GILMER J., YOSINSKI J., SOHL-DICKSTEIN J. *SVCCA: Singular Vector Canonical Correlation Analysis for Deep Learning Dynamics and Interpretability* // The 34th Conference on Neural Information Processing Systems (NeurIPS), Sydney, Australia, August 6-11, 2017, Proceedings. – 2017.
- [23] REZENDE D. J., MOHAMED S., WIERSTRA D. *Stochastic backpropagation and approximate inference in deep generative models* // The 31st International Conference on Machine Learning (ICML), Beijing, China, June 21–26, 2014, Proceedings. – 2014 – P.1278-1286.
- [24] ROEDER G., METZ L., KINGMA D. P. *On Linear Identifiability of Learned Representations* // The International Conference on Machine Learning (ICML), Vienna, Austria, July 18–24, 2021, Proceedings. – 2021.
- [25] SCHUERHOLT K., KOSTADINOV D., BORTH D., LUGO-MARTINEZ J. *Hyper-Representations as Generative Models: Sampling Unseen Neural Network Weights* // The 36th Conference on Neural Information Processing

- Systems (NeurIPS), New Orleans, USA, November 28 to December 9, 2022, Proceedings. – 2022.
- [26] SCHURHOLT K., MEYNENT L., ZHOU Y., LU H., YANG Y., BORTH D. *A Model Zoo on Phase Transitions in Neural Networks* // Journal of Data-centric Machine Learning Research. – 2025.
- [27] STEWART G. W., SUN J. G. *Matrix perturbation theory* // M.: Elsevier Science, 1990. – 374 с.
- [28] WEYL H. *Das asymptotische Verteilungsgesetz der Eigenwerte linearer partieller Differentialgleichungen (mit einer Anwendung auf die Theorie der Hohlraumstrahlung)* // Mathematische Annalen. – 1912. – Vol. 71, No. 4. – P. 441–479.
- [29] XIAO H., RASUL K., VOLLGRAF R. *Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms* // arXiv – 15.10.2017. – URL: <https://arxiv.org/abs/1708.07747> (дата обращения: 5.07.25).
- [30] YANG C., SHEN Y. ZHOU B. TANG X. *InterFaceGAN: Interpreting the Disentangled Face Representation Learned by GANs* // IEEE Transactions on Pattern Analysis and Machine Intelligence. – 2022. – Vol. 4, No. 4. – P. 2004–2018.