

Спектральные характеристики параметров автокодировщика как векторное представление данных

Мария Александровна Никитина

Московский физико-технический институт

Кафедра: Интеллектуальный анализ данных

Консультант: аспирант А. Ю. Бишук

Научный руководитель: кандидат ф.-м. наук О. Ю. Бахтеев

2026

Постановка задачи

Исследуется взаимосвязь между параметрами моделей автокодировщиков и статистическими свойствами данных, на которых они обучались.


Проблема

Существующие подходы к анализу автокодировщиков основаны преимущественно на качестве реконструкции и скрытых представлениях. При этом упускается связь со статистической информацией о данных.

Задача

Предложить метод отображения моделей в векторное пространство, основанный на спектральных характеристиках параметров автокодировщика, который формирует представление, отражающее статистические свойства исходных данных.

Требования к представлению



1. Инвариантность относительно симметрий пространства параметров;
2. Сохранение статистических характеристик распределения обучающей выборки, в частности, структуры смеси распределения;
3. Линейная разделимость множеств векторов моделей, обученных на данных из различных распределений.

Пусть p_c — распределение данных класса $c \in \{1, 2, \dots\}$ на $\mathbb{R}^d$.
 $\mathbf{X}_c = \{\mathbf{x}_i : \mathbf{x}_i \sim p_c\}_{i=1}^n$ — выборка, порождённая распределением.

ψ — параметры модели автокодировщика, обученной на $\mathbf{X}_c$.

$\sigma^{\text{model}} = \sigma_1^{\text{model}}, \dots, \sigma_m^{\text{model}}$ — сингулярные числа матриц параметров модели $\mathbf{W}$.

$\sigma^{\text{data}} = \sigma_1^{\text{data}}, \dots, \sigma_m^{\text{data}}$ — сингулярные числа матриц данных.

Подмешивание $\tilde{\mathbf{X}}_{a|b} = [\mathbf{X}_a, \mathbf{X}_b] \in \mathbb{R}^{(n+n) \times d}$ — конкатенация векторов из $\mathbf{X}_a$ и $\mathbf{X}_b$.

Предложенный метод

Способ векторизации

Основная гипотеза состоит в том, что параметры модели и их сингулярные числа сохраняют статистическую информацию о данных, на которых модель обучалась.

$$\sigma^{\text{model}}(\psi) = \text{CONCAT}(\sigma_1^{\text{model}}(\mathbf{W}_1), \dots, \sigma_s^{\text{model}}(\mathbf{W}_s))$$

Алгоритм

1. Обучение автокодировщика (AE/VAE) на выборке;
2. Извлечение матриц весов из всех слоёв модели;
3. Вычисление сингулярных чисел для каждой матрицы весов;
4. Конкатенация сингулярных чисел в единый вектор;
5. Отбор первых r сингулярных чисел.

Сингулярные числа выборок

Гипотеза

Чем ближе векторы сингулярных чисел исходных выборок, тем хуже линейная разделимость векторов сингулярных чисел соответствующих им моделей.

Лемма (Никитина, 2025)

Пусть заданы матрицы данных $\mathbf{X}_1 \in \mathbb{R}^{n_1 \times d}$, $\mathbf{X}_2 \in \mathbb{R}^{n_2 \times d}$, $\mathbf{X}_3 \in \mathbb{R}^{m \times d}$. Тогда сингулярные числа матриц $\tilde{\mathbf{X}}_{1|3}$, $\tilde{\mathbf{X}}_{2|3}$, образованных подмешиванием векторов $\mathbf{X}_3$ к $\mathbf{X}_1$ и $\mathbf{X}_2$ соответственно, сближаются. То есть:

$$|\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_{1|3}) - \sigma_i^{\text{data}}(\tilde{\mathbf{X}}_{2|3})| \longrightarrow 0 \quad \text{при } m \rightarrow \infty$$

где $\sigma_i^{\text{data}}(\tilde{\mathbf{X}}_{c|3})$ — i -ое сингулярное число выборки $\tilde{\mathbf{X}}_{c|3}$, образованной подмешиванием векторов $\mathbf{X}_3$ к $\mathbf{X}_c$.

Связь сингулярных чисел параметров модели с данными

Теорема (Никитина, 2025)

$\tilde{\mathbf{X}}_{c|3} = [\mathbf{X}_c, \mathbf{X}_3] \in \mathbb{R}^{(n+m) \times d}$ — новые выборки, сформированные подмешиванием, $c \in \{1, 2\}$.

На каждой выборке обучена модель линейного автокодировщика параметрами ψ_c , имеющими вид матриц $\mathbf{W}_c^{enc}$, $\mathbf{W}_c^{dec}$, минимизирующая функцию ошибки $\mathcal{L}$:

$$\min_{\psi_c} (\mathcal{L}(\psi_c)) = \min_{\psi_c} \|\tilde{\mathbf{X}}_{c|3} - \tilde{\mathbf{X}}_{c|3} \mathbf{W}_c^{enc} \mathbf{W}_c^{dec \top}\|_F^2$$

с регуляризацией вида $\|\text{cov}(\mathbf{h}) - \mathbf{I}\|^2$, декоррелирующей векторы $\mathbf{h}$ из скрытого пространства, то есть $\text{cov}(\mathbf{h}) \sim \mathbf{I}$.

Тогда средний квадрат разности между сингулярными числами параметров автокодировщиков:

$$\|\sigma_i^{\text{model}}(\mathbf{W}_1^{enc}) - \sigma_i^{\text{model}}(\mathbf{W}_2^{enc})\|_2 \xrightarrow{m \rightarrow \infty} 0$$

Настройки вычислительного эксперимента

Данные

1. CIFAR-10¹: 3 наиболее отличающихся класса;
2. FashionMNIST: все 10 классов.

Модели

1. Автокодировщик и вариационный автокодировщик;
2. Архитектура: 1-2 линейных слоя, скрытое пространство размерности 256.

Метрики


1. Accuracy, ROC AUC, Average Precision;
2. Классификация: логистическая регрессия с L_2 -регуляризацией;
3. Статистика: среднее по 5 запускам с различными подвыборками.

¹ Krizhevsky A. *Learning Multiple Layers of Features from Tiny Images*, 2009

Базовый эксперимент

Разделение двух классов

1. Для линейных AE: Accuracy = $0.98(\pm 0.02)$;
2. Для VAE: Accuracy = $0.97(\pm 0.03)$;




Векторы сингулярных чисел позволяют почти идеально разделять модели, обученные на разных классах.

Подмешивание третьего класса

Зависимость качества от доли третьего класса


1. Эксперимент для 3 различных вариантов семплирования третьего класса;
2. Качество существенно зависит от α — доли третьего класса в выборке.



Корреляция с сингулярными числами данных

Иллюстрация Теоремы

Расстояние между векторами сингулярных чисел матриц параметров моделей линейно зависит от расстояния между сингулярными числами выборок.



Попарные сравнения классов

Матрица разделимости для FashionMNIST

Качество разделения векторов моделей с помощью логистической регрессии коррелирует с визуальным и статистическим различием классов.

	T-shirt/Top	Trouser	Pullover	Dress	Coat	Sandals	Shirt	Sneaker	Bag	Ankle Boots
T-shirt/Top	1.00	0.00	0.02	0.02	0.00	0.00	0.05	0.00	0.00	0.00
Trouser	1.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Pullover	0.95	1.00	1.00	0.02	0.01	0.00	0.01	0.00	0.00	0.00
Dress	0.93	1.00	0.94	1.00	0.02	0.00	0.02	0.01	0.00	0.02
Coat	1.00	1.00	0.97	0.93	1.00	0.00	0.02	0.00	0.00	0.00
Sandals	1.00	1.00	1.00	1.00	1.00	1.00	0.03	0.00	0.00	0.00
Shirt	0.85	1.00	0.97	0.94	0.93	0.93	1.00	0.00	0.00	0.00
Sneaker	1.00	1.00	1.00	0.97	1.00	1.00	1.00	1.00	0.00	0.00
Bag	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	0.00
Ankle Boots	1.00	1.00	1.00	0.95	1.00	1.00	1.00	1.00	1.00	1.00

Нижняя треугольная матрица — среднее качество логистической регрессии при разделении векторов моделей, верхняя треугольная матрица — std качества логистической регрессии, диагональ — среднее качество логистической регрессии в эксперименте one-vs-rest.

1. Разработан метод векторизации моделей на основе сингулярных чисел параметров. Построенное таким образом векторное представление обладает статистической информацией об обучающих выборках.
2. Доказана теоретическая связь спектра параметров и данных для моделей автокодировщиков. Расстояние между векторами сингулярных чисел параметров моделей тем меньше, чем ближе распределения обучающих данных.
3. В серии экспериментов проанализированы свойства векторных представлений моделей АЕ и VAE в зависимости от способа порождения обучающих данных. Экспериментально подтверждено утверждение теоремы.

1. Статья опубликована: Бишук А.Ю., Никитина М.А., Бахтеев О.Ю. *Спектральные характеристики параметров автокодировщика как векторное представление данных* // Управление большими системами. - 2026. - Вып. 120. - С.51-83.
2. Выступление и тезисы: Никитина М.А, Бишук А.Ю. *Геометрически согласованные векторные представления генеративных моделей на основе кластерного базиса латентного пространства.* // 68-я Всероссийская научная конференция МФТИ

Список литературы

- [1] Achille A., Soatto S., Antonio Torralba, Stefanie Jegelka (2018)
Information Dropout: learning optimal representations through noisy computation
- [2] Kingma D. P., Welling M. (2022)
Auto-Encoding Variational Bayes
- [3] Klabunde M., Schumacher T., Strohmaier M., Lemmerich F. (2025)
Similarity of Neural Network Models: A Survey of Functional and Representational Measures
- [4] Akhauri Y., Abdelfattah M. S. (2024)
Encodings for Prediction-based Neural Architecture Search
- [5] Schurholt K., Meynert L., Zhou Y., Lu H., Yang Y., Borth D. (2025)
A Model Zoo on Phase Transitions in Neural Networks